LAB-01 — Protección y privacidad de datos

Materia: Gestión de Seguridad y Desempeño de Bases de Datos
Unidad: II — Seguridad, privacidad y control de acceso
Actividad: Anonimización y análisis del riesgo de reidentificación
Estudiante: Carlos Romero
Grupo: 4

Actividad — Anonimización y análisis del riesgo de reidentificación

Objetivo

El objetivo de esta actividad es generar información estadística y agregada que permita utilizar los datos de los clientes reduciendo el riesgo de identificación individual.

Para ello se aplicaron técnicas de generalización, agregación y supresión de grupos pequeños sobre atributos que pueden funcionar como cuasi-identificadores, particularmente la edad y el código postal.

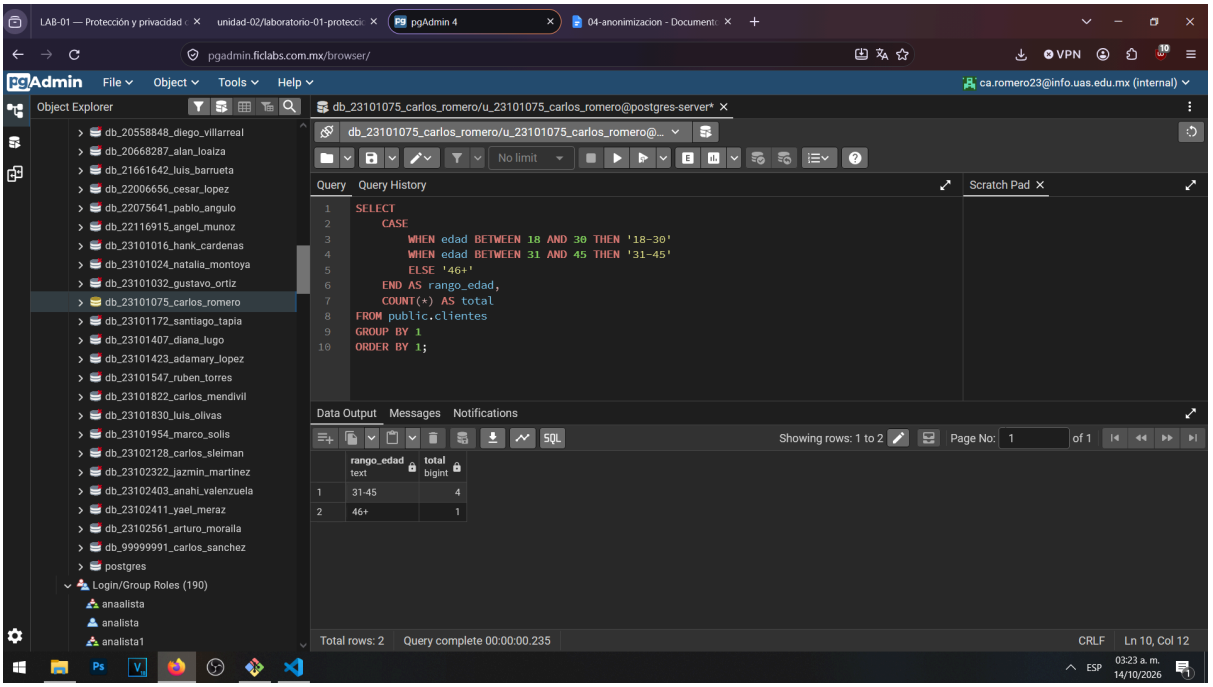
Evidencia 1 — Generalización de la edad

La primera transformación consistió en sustituir la edad exacta de cada cliente por un rango de edad.

Se ejecutó la siguiente consulta:

```
SELECT
   CASE
      WHEN edad BETWEEN 18 AND 30 THEN '18-30'
      WHEN edad BETWEEN 31 AND 45 THEN '31-45'
      ELSE '46+'
   END AS rango_edad,
   COUNT(*) AS total
FROM public.clientes
GROUP BY 1
ORDER BY 1;
```

Captura de evidencia



Resultado

La consulta agrupó los cinco clientes en rangos de edad.

Se obtuvieron cuatro registros dentro del rango 31-45 y un registro dentro del rango 46+.

La generalización reduce el nivel de detalle debido a que ya no se presenta la edad exacta de cada persona.

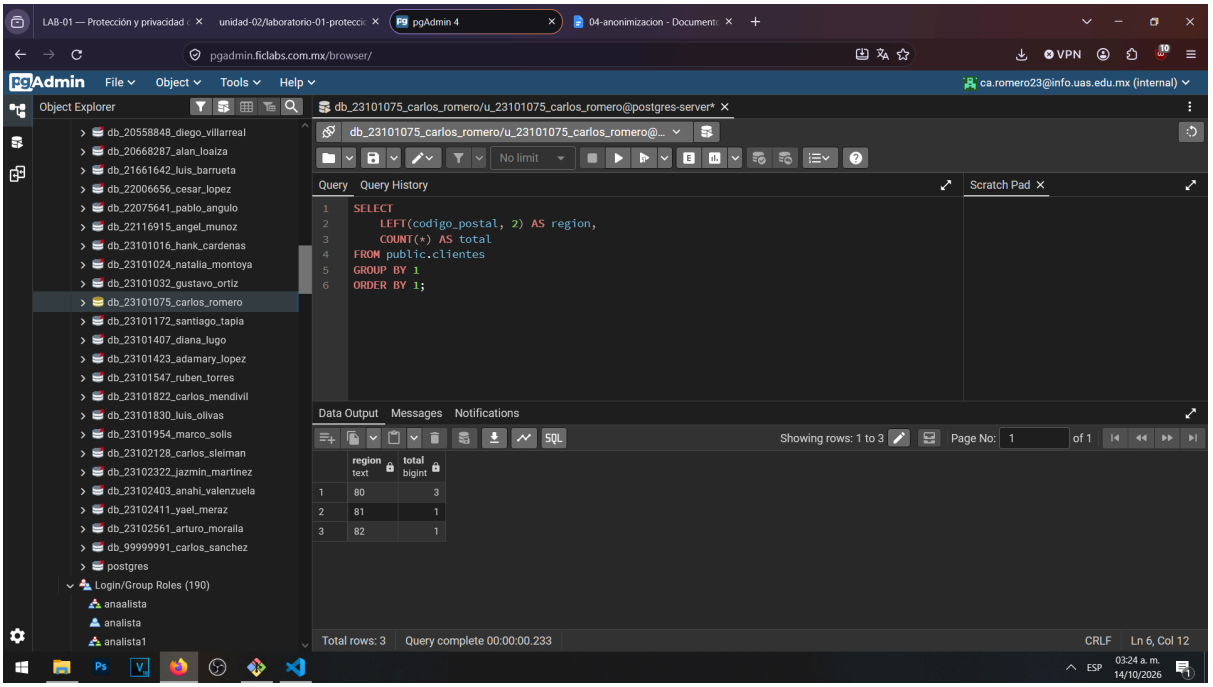
Evidencia 2 — Generalización de la región postal

Posteriormente se redujo el nivel de detalle del código postal utilizando únicamente sus primeros dos caracteres.

La consulta utilizada fue:

```
SELECT
    LEFT(codigo_postal, 2) AS region,
    COUNT(*) AS total
FROM public.clientes
GROUP BY 1
ORDER BY 1;
```

Captura de evidencia



Resultado

Los códigos postales fueron agrupados en tres regiones:

80 → 3 registros
81 → 1 registro
82 → 1 registro

La transformación evita mostrar el código postal completo y reduce la precisión geográfica de la información.

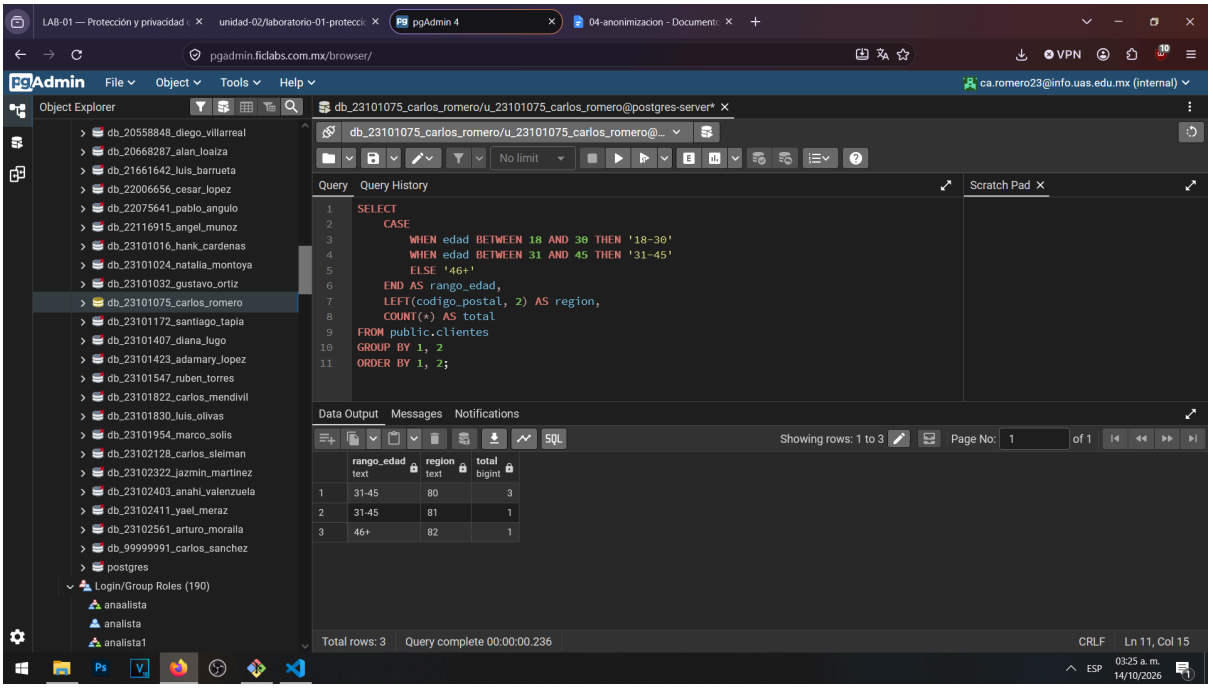
Evidencia 3 — Combinación de cuasi-identificadores

Se combinaron el rango de edad y la región postal para analizar el tamaño de los grupos generados.

La consulta utilizada fue:

```
SELECT
   CASE
      WHEN edad BETWEEN 18 AND 30 THEN '18-30'
      WHEN edad BETWEEN 31 AND 45 THEN '31-45'
      ELSE '46+'
   END AS rango_edad,
   LEFT(codigo_postal, 2) AS region,
   COUNT(*) AS total
FROM public.clientes
GROUP BY 1, 2
ORDER BY 1, 2;
```

Captura de evidencia



Resultado

Se obtuvieron los siguientes grupos:

31-45 / región 80 → 3 registros
31-45 / región 81 → 1 registro
46+ / región 82 → 1 registro

Aunque los datos han sido generalizados, todavía existen grupos formados por una sola persona.

Esto demuestra que eliminar los identificadores directos o generalizar algunos atributos no garantiza automáticamente la anonimización, debido a que los cuasi-identificadores todavía pueden generar grupos muy pequeños.

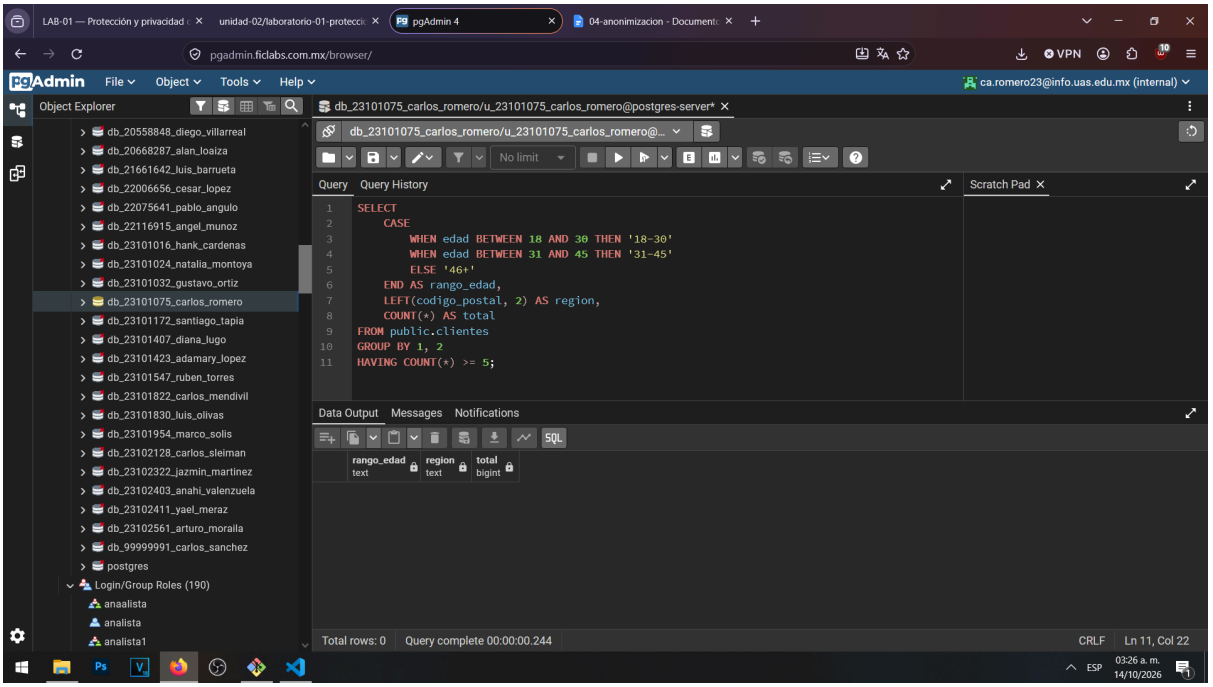
Evidencia 4 — Supresión de grupos pequeños

Como ejercicio didáctico se utilizó un umbral mínimo de cinco registros mediante:

```
SELECT
  CASE
    WHEN edad BETWEEN 18 AND 30 THEN '18-30'
    WHEN edad BETWEEN 31 AND 45 THEN '31-45'
    ELSE '46+'
  END AS rango_edad,
  LEFT(codigo_postal, 2) AS region,
  COUNT(*) AS total
```

```
FROM public.clientes
GROUP BY 1, 2
HAVING COUNT(*) >= 5;
```

Captura de evidencia



Resultado

La consulta no devolvió registros debido a que ninguna combinación de rango de edad y región contiene cinco o más clientes.

El resultado de 0 rows es correcto y demuestra que todos los grupos obtenidos anteriormente son menores al umbral utilizado en el ejercicio.

El valor 5 se utiliza únicamente como criterio didáctico y no significa que cumplir dicho umbral garantice por sí mismo una anonimización completa.

Evidencia 5 — Reto: aumento de la generalización

Para reducir aún más el riesgo de reidentificación se modificaron los niveles de generalización.

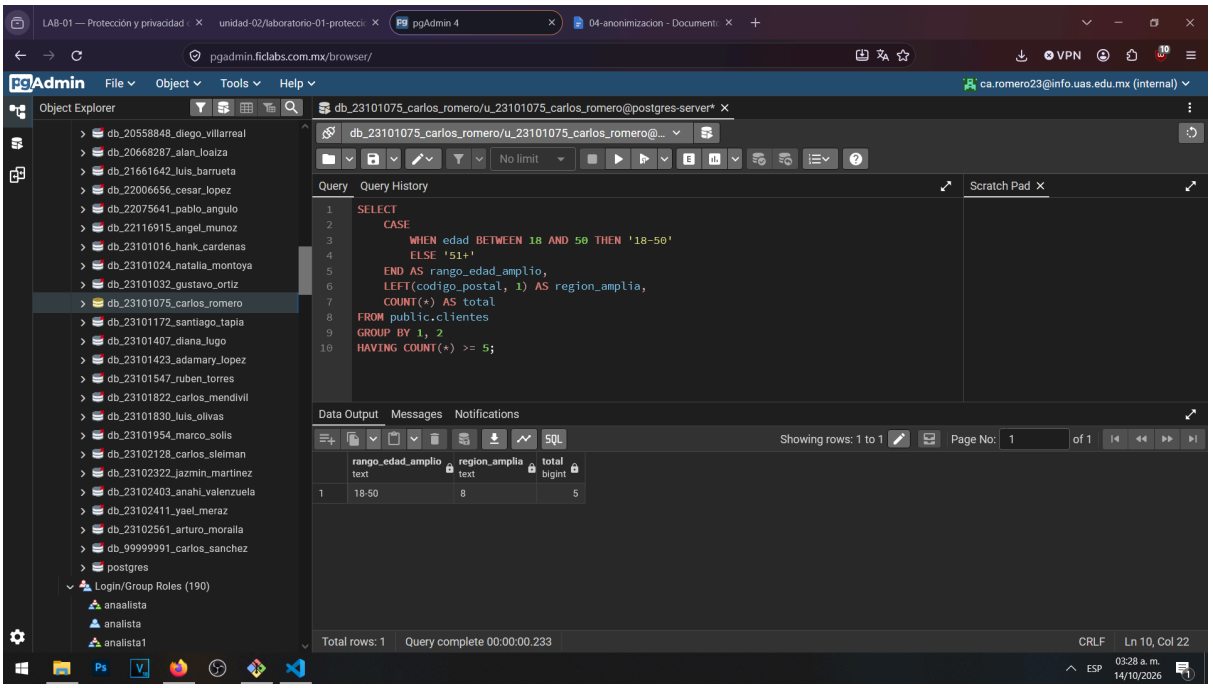
La edad se agrupó en un rango más amplio y el código postal se redujo únicamente a su primer carácter.

También se aplicó nuevamente el umbral mínimo de cinco registros.

La consulta utilizada fue:

```
SELECT
   CASE
      WHEN edad BETWEEN 18 AND 50 THEN '18-50'
      ELSE '51+'
   END AS rango_edad_amplio,
   LEFT(codigo_postal, 1) AS region_amplia,
   COUNT(*) AS total
FROM public.clientes
GROUP BY 1, 2
HAVING COUNT(*) >= 5;
```

Captura de evidencia



Resultado

Después de aumentar la generalización se obtuvo un grupo con las siguientes características:

Rango de edad: 18-50
Región amplia: 8
Total: 5

Los cinco clientes quedaron agrupados dentro del mismo conjunto.

Esto reduce el nivel de detalle disponible y dificulta distinguir individualmente a una persona utilizando solamente los atributos generalizados.

Sin embargo, alcanzar un grupo de cinco registros no demuestra por sí mismo que el conjunto sea completamente anónimo. El riesgo debe evaluarse considerando todos los

atributos disponibles, el contexto y la posibilidad de combinar la información con fuentes externas.

Resultado general de la actividad

Las pruebas realizadas demostraron que la generalización y la agregación permiten reducir el nivel de detalle de los datos.

También se comprobó que combinar distintos cuasi-identificadores puede producir grupos pequeños y aumentar el riesgo de reidentificación.

Al ampliar los rangos utilizados para la edad y la región fue posible formar un grupo de cinco registros, reduciendo la capacidad de distinguir a individuos dentro del conjunto.